

EcAuTAL

École d'Automne en TAL

Exploration d'un corpus clinique : un cas d'étude du projet PARTAGES

Laura Zanella

Postdoctorante, LISN, équipe SEME

22 octobre 2026





université
PARIS-SACLAY



PARTAGES

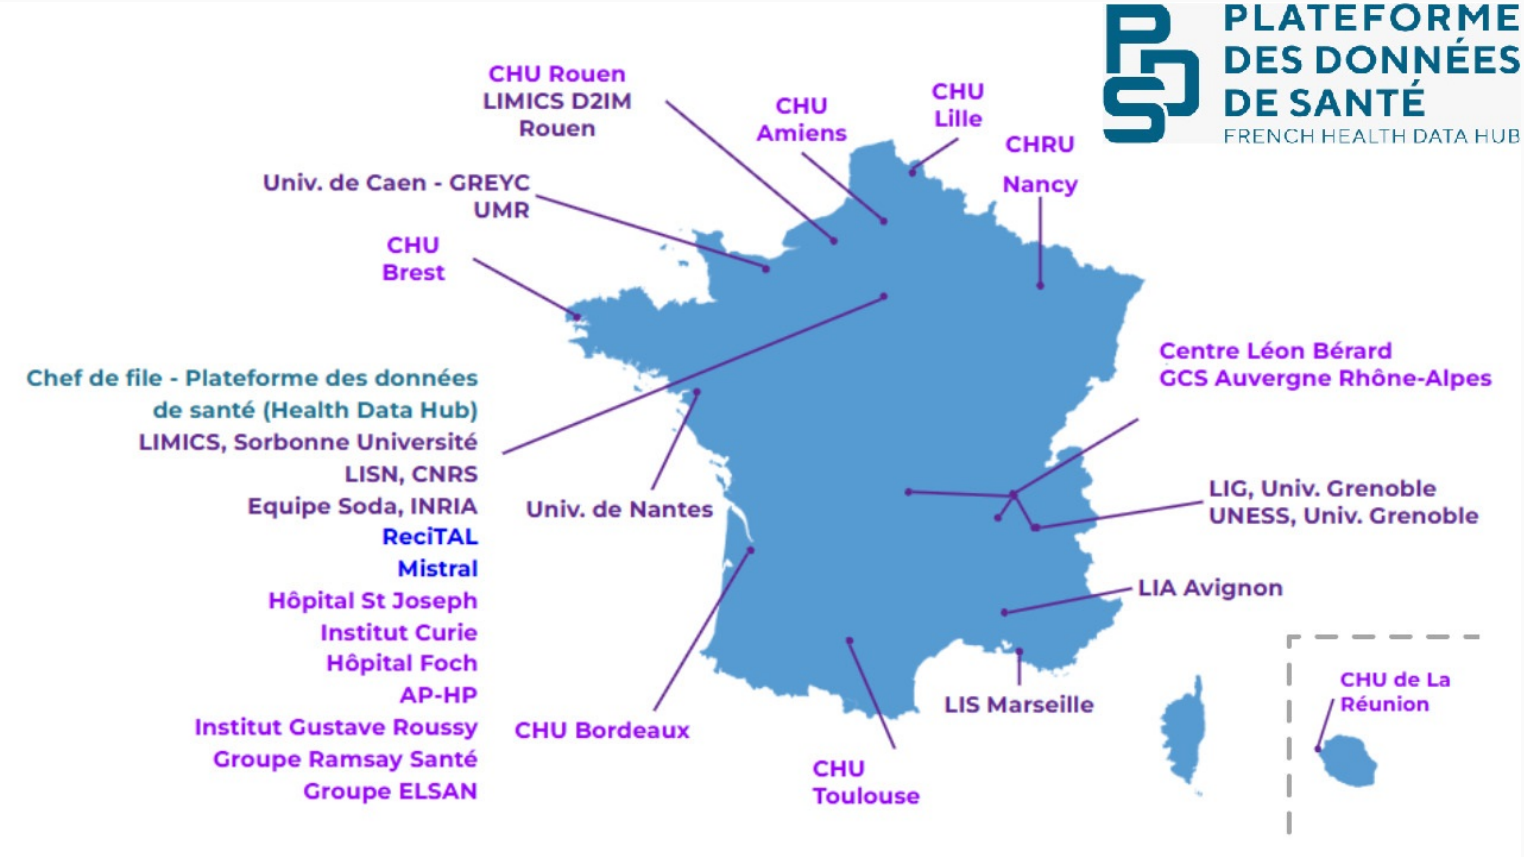
DévelopPement Avancé de communs numéRiques pour l'inTelligence Artificielle Générative En Santé

Introduction de PARTAGES

Introduction du projet PARTAGES

Projet lauréat de « Communs numériques pour l'IA générative » du plan France 2030.

« [PARTAGES] vise à accélérer et démocratiser l'usage des grands modèles de langage (LLM) au service des professionnels de santé. »



32 acteurs partenaires

Le projet en quatre grandes étapes

1. **Développer des LLM médicaux**

   Constitution d'un corpus de données textuelles médicales en français pour entraîner, évaluer et diffuser plusieurs modèles de langage open source.

2. **Créer une base ouverte de comptes rendus médicaux fictifs**

   Création d'un corpus d'environ 6.000 comptes rendus médicaux fictifs, couvrant 20 spécialités.

3. **Développer des modèles pour des cas d'usage ciblés**

   Conception de sept modèles d'IA spécialisés pour répondre à des thématiques à fort impact en recherche, en innovation et dans le système de soins.

4. **Mettre en place une plateforme nationale d'évaluation fédérée**

   Développement d'une plateforme souveraine permettant d'évaluer des algorithmes sur des données réelles dans un cadre sécurisé et conforme à la réglementation.

Composantes du projet auxquelles je contribue.

Équipe d’évaluation des modèles et de cas d’usage

Notre équipe au LISN est chargée de développer des systèmes d’évaluation pour les **modèles de fondation** développés dans le projet, ainsi que pour les différentes tâches associées aux **cas d’usage (CU)**.



DR Aurélie Névéol



DR émérite Pierre Zweigenbaum



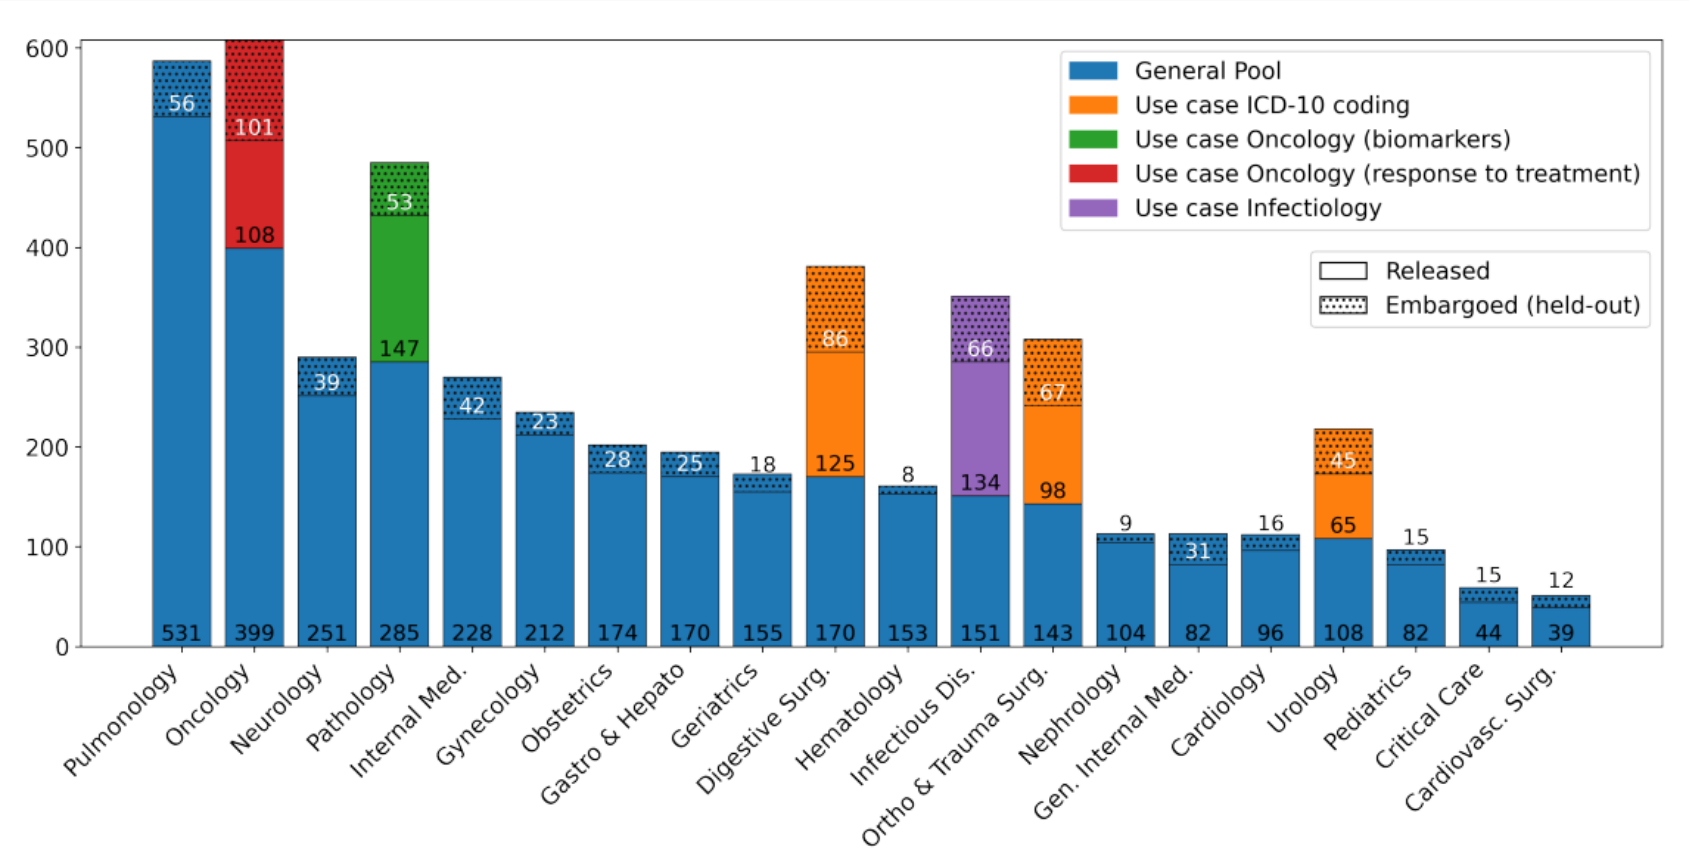
IE Takuya Nakamura



Laura Zanella

Corpus de comptes rendus fictifs : PARHAF

PARHAF[1] est un corpus de plus de 6.000 comptes rendus (CR) médicaux fictifs, créés par plus de 120 internes et médecins.



[1] PARHAF, a human-authored corpus of clinical reports for fictitious patients in French

Comment le corpus PARHAF a-t-il été constitué ?

Un scénario structuré sert de point de départ à la rédaction humaine d'un CR fictif.

Scénario proposé

```
{
  'name': 'Gaela Berton',
  'age': 71,
  'sex': 'F',
  'admission_mode':
   'domicile',
  'discharge_mode':
   'retour à domicile',
  'primary_diagnosis':
   'D128',
   'Tumeur bénigne du rectum',
  'type_of_care':
   'Endoscopies digestives
   avec ou sans anesthésie,
   en ambulatoire'
}
```

→

Compte rendu fictif rédigé

Compte rendu d'hospitalisation du service de Gastro-entérologie

Madame Gaela Berton, 71 ans, est hospitalisée en hôpital de jour de Gastro-entérologie le 09/08/2025.

Motif d'hospitalisation
Bilan endoscopique.

Antécédents médicaux, chirurgicaux, familiaux, allergies
Médicaux : HTA, dyslipidémie, surpoids (IMC 28.5 kg/m^2). Familiaux : cancer du côlon chez le frère à l'âge de 68 ans.
Allergies : aucune.

Histoire de la maladie
Patiente ayant consulté le Dr LEPELLE suite au diagnostic chez son frère d'un cancer du côlon métastatique en janvier 2025.

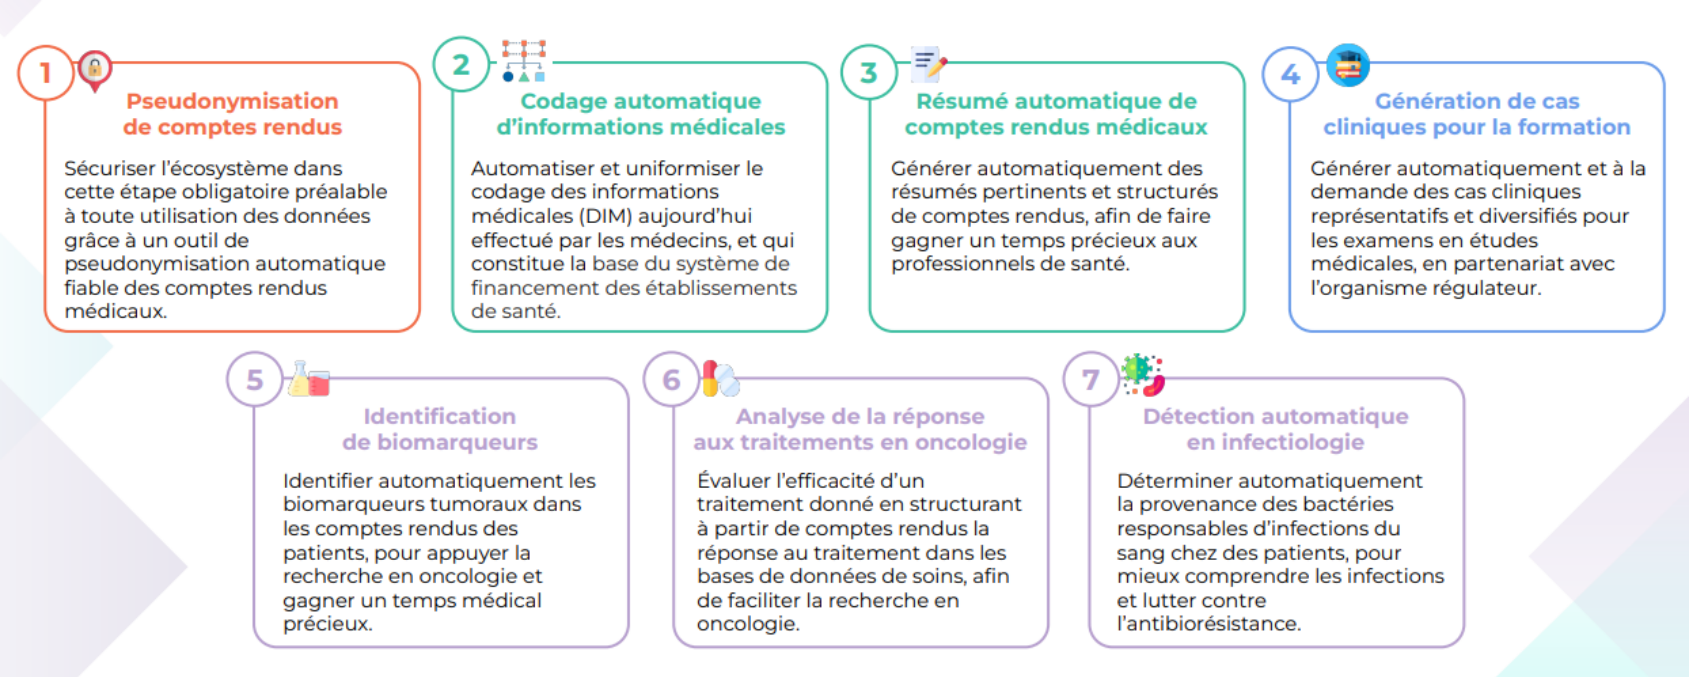
Examens complémentaires
Coloscopie du 09/08/2025 : iléon, caecum et côlon d'aspect normal. Rectum : quelques polypes d'allure hyperplasiques.

Conclusion
Coloscopie bien préparée avec aspect normal. Pas d'anomalie retrouvée en dehors de polypes hyperplasiques du rectum. Prochain contrôle endoscopique dans 5 ans si l'état général le permet.

Fait à Versailles le 05/10/2025,
Signataire : Dr Emanuelle Chonavey.

Cas d'usage ciblés de PARTAGES

Sept différents cas d'usage liés à des tâches d'**identification et reconnaissance d'entités**, **classification de texte**, **extraction de relations**, **génération de texte**, ...



Focus sur le cas d’usage 3 : Génération de résumés cliniques

Évaluer des résumés cliniques générés : trois questions clés

1. **Que cherche-t-on à produire ?**
   Qu'attend-on d'un résumé clinique de qualité ?

2. **À quoi comparer les résumés générés ?**
   De quel point de référence dispose-t-on pour les évaluer ?

3. **Comment évaluer leur qualité ?**
   Quels critères permettent d'en mesurer les différentes dimensions ?

Définition de la tâche du CU3

Le CU3 vise à générer automatiquement des résumés pertinents de CR médicaux pour faire gagner du temps aux professionnels de santé.

Cette définition soulève deux questions :

(1) **Qu'est-ce qu'un résumé ?** (principal point de cette présentation)

(2) **Comment évalue-t-on sa pertinence ?** (une brève introduction)

Définition de la tâche du CU3

Le CU3 vise à générer automatiquement des résumés pertinents de CR médicaux pour faire gagner du temps aux professionnels de santé.

Cette définition soulève deux questions :

(1) Qu'est-ce qu'un résumé ? (principal point de cette présentation)

(2) Comment évalue-t-on sa pertinence ? (une brève introduction)

Définition de la tâche du CU3

Le CU3 vise à générer automatiquement des résumés pertinents de CR médicaux pour faire gagner du temps aux professionnels de santé.

Cette définition soulève deux questions :

(1) Qu'est-ce qu'un résumé ? (principal point de cette présentation)

(2) Comment évalue-t-on sa pertinence ? (une brève introduction)

Qu’est-ce qu’un résumé ?

Qu’est-ce qu’un résumé ?

Un résumé peut être défini selon plusieurs perspectives :

NLP / Linguistique

Une transformation réductive du texte source qui **préserve les informations importantes du sens original**. (Sparck Jones, 1999)

Fonctionnelle / Clinique

Une information permettant au clinicien suivant de comprendre **l’événement, les décisions et les résultats**. (Kripalani et al., 2007)

Réglementaire

Le résumé de sortie doit notamment préciser :

- le diagnostic principal ;
- les procédures et traitements effectués ;
- les prescriptions de sortie et recommandations ;
- le suivi recommandé.

(Décret n° 2016-995)

Sparck Jones, K. (1999). Automatic summarising: factors and directions.

Kripalani, S., LeFevre, F., Phillips, C. O., et al. (2007). Deficits in communication and information transfer between hospital-based and primary care physicians.

Qu’est-ce qu’un résumé ?

Un résumé peut être défini selon plusieurs perspectives :

NLP / Linguistique

Une transformation réductive du texte source qui **préserve les informations importantes du sens original**. (Sparck Jones, 1999)

Fonctionnelle / Clinique

Une information permettant au clinicien suivant de comprendre **l’événement, les décisions et les résultats**. (Kripalani et al., 2007)

Réglementaire

Le résumé de sortie doit notamment préciser :

- le diagnostic principal ;
- les procédures et traitements effectués ;
- les prescriptions de sortie et recommandations ;
- le suivi recommandé.

(Décret n° 2016-995)

Sparck Jones, K. (1999). Automatic summarising: factors and directions.

Kripalani, S., LeFevre, F., Phillips, C. O., et al. (2007). Deficits in communication and information transfer between hospital-based and primary care physicians.

Qu’est-ce qu’un résumé ?

Un résumé peut être défini selon plusieurs perspectives :

NLP / Linguistique

Une transformation réductive du texte source qui **préserve les informations importantes du sens original**. (Sparck Jones, 1999)

Fonctionnelle / Clinique

Une information permettant au clinicien suivant de comprendre **l’événement, les décisions et les résultats**. (Kripalani et al., 2007)

Réglementaire

Le résumé de sortie doit notamment préciser :

- le diagnostic principal ;
- les procédures et traitements effectués ;
- les prescriptions de sortie et recommandations ;
- le suivi recommandé.

(Décret n° 2016-995)

Sparck Jones, K. (1999). Automatic summarising: factors and directions.

Kripalani, S., LeFevre, F., Phillips, C. O., et al. (2007). Deficits in communication and information transfer between hospital-based and primary care physicians.

Plusieurs manières de concrétiser un résumé

Même si les définitions donnent des principes généraux, **plusieurs résumés peuvent être produits à partir d'un même CR**, selon les informations retenues et la manière de les reformuler.

Compte rendu d'hospitalisation du service de Gastro-entérologie

Madame Gaela Berton, 71 ans, est hospitalisée en hôpital de jour de Gastro-entérologie le 09/08/2025.

Motif d'hospitalisation Bilan endoscopique.

Antécédents médicaux, chirurgicaux, familiaux, allergies Médicaux : HTA, dyslipidémie, surpoids (IMC 28.5 kg/m²). Familiaux : cancer du côlon chez le frère à l'âge de 68 ans. Allergies : paracétamol.

Examens complémentaires Coloscopie du 09/08/2025 : iléon, caecum et côlon d'aspect normal. Rectum : quelques polypes d'allure hyperplasiques.

Extractif

Reprendre des segments du CR
« Hospitalisée le 09/08/2025 pour bilan endoscopique. Iléon, caecum et côlon d'aspect normal. Rectum : quelques polypes d'allure hyperplasiques. »

Abstractif

Reformuler le texte du CR
« La coloscopie retrouve un tube digestif d'aspect normal jusqu'au côlon, hormis quelques polypes rectaux d'allure hyperplasique. L'examen se déroule sans complication. »

Plusieurs manières de concrétiser un résumé

Même si les définitions donnent des principes généraux, **plusieurs résumés peuvent être produits à partir d'un même CR**, selon les informations retenues et la manière de les reformuler.

Compte rendu d'hospitalisation du service de Gastro-entérologie

Madame Gaela Berton, 71 ans, est hospitalisée en hôpital de jour de Gastro-entérologie le 09/08/2025.

Motif d'hospitalisation Bilan endoscopique.

Antécédents médicaux, chirurgicaux, familiaux, allergies Médicaux : HTA, dyslipidémie, surpoids (IMC 28.5 kg/m²). Familiaux : cancer du côlon chez le frère à l'âge de 68 ans. Allergies : paracétamol.

Examens complémentaires Coloscopie du 09/08/2025 : iléon, caecum et côlon d'aspect normal. Rectum : quelques polypes d'allure hyperplasiques.

Extractif

Reprendre des segments du CR
« Hospitalisée le 09/08/2025 pour bilan endoscopique. Iléon, caecum et côlon d'aspect normal. Rectum : quelques polypes d'allure hyperplasiques. »

Abstractif

Reformuler le texte du CR
« La coloscopie retrouve un tube digestif d'aspect normal jusqu'au côlon, hormis quelques polypes rectaux d'allure hyperplasique. L'examen se déroule sans complication. »

Plusieurs manières de concrétiser un résumé

Même si les définitions donnent des principes généraux, **plusieurs résumés peuvent être produits à partir d'un même CR**, selon les informations retenues et la manière de les reformuler.

Compte rendu d'hospitalisation du service de Gastro-entérologie

Madame Gaela Berton, 71 ans, est hospitalisée en hôpital de jour de Gastro-entérologie le 09/08/2025.

Motif d'hospitalisation Bilan endoscopique.

Antécédents médicaux, chirurgicaux, familiaux, allergies Médicaux : HTA, dyslipidémie, surpoids (IMC 28.5 kg/m²). Familiaux : cancer du côlon chez le frère à l'âge de 68 ans. Allergies : paracétamol.

Examens complémentaires Coloscopie du 09/08/2025 : iléon, caecum et côlon d'aspect normal. Rectum : quelques polypes d'allure hyperplasiques.

Extractif

Reprendre des segments du CR
« Hospitalisée le 09/08/2025 pour bilan endoscopique. Iléon, caecum et côlon d'aspect normal. Rectum : quelques polypes d'allure hyperplasiques. »

Abstractif

Reformuler le texte du CR
« La coloscopie retrouve un tube digestif d'aspect normal jusqu'au côlon, hormis quelques polypes rectaux d'allure hyperplasique. L'examen se déroule sans complication. »

Plusieurs manières de concrétiser un résumé

Même si les définitions donnent des principes généraux, **plusieurs résumés peuvent être produits à partir d'un même CR**, selon les informations retenues et la manière de les reformuler.

Compte rendu d'hospitalisation du service de Gastro-entérologie

Madame Gaela Berton, 71 ans, est hospitalisée en hôpital de jour de Gastro-entérologie le 09/08/2025.

Motif d'hospitalisation Bilan endoscopique.

Antécédents médicaux, chirurgicaux, familiaux, allergies Médicaux : HTA, dyslipidémie, surpoids (IMC 28.5 kg/m²). Familiaux : cancer du côlon chez le frère à l'âge de 68 ans. Allergies : paracétamol.

Examens complémentaires Coloscopie du 09/08/2025 : iléon, caecum et côlon d'aspect normal. Rectum : quelques polypes d'allure hyperplasiques.

Extractif

Reprendre des segments du CR
« Hospitalisée le 09/08/2025 pour bilan endoscopique. Iléon, caecum et côlon d'aspect normal. Rectum : quelques polypes d'allure hyperplasiques. »

Abstractif

Reformuler le texte du CR
« La coloscopie retrouve un tube digestif d'aspect normal jusqu'au côlon, hormis quelques polypes rectaux d'allure hyperplasique. L'examen se déroule sans complication. »

Hybride

Reprendre des segments et reformuler le texte du CR
« Madame Gaela Berton, 71 ans, est hospitalisée en hôpital de jour de Gastro-entérologie le 09/08/2025. Coloscopie réalisée sans anomalie notable en dehors de polypes hyperplasiques du rectum. »

Les conclusions des CR sont-elles des résumés ?

Pour évaluer un résumé généré, on peut le comparer à un **résumé de référence**, c'est-à-dire un résumé validé qui sert de point de comparaison.

Dans le cadre du CU3, nous avons initialement fait l'hypothèse que les conclusions déjà présentes dans les CR pouvaient jouer ce rôle.

Compte rendu d'hospitalisation du service de Gastro-entérologie

Madame Gaela Berton, 71 ans, est hospitalisée en hôpital de jour de Gastro-entérologie le 09/08/2025.

Motif d'hospitalisation
Bilan endoscopique.

Antécédents médicaux, chirurgicaux, familiaux, allergies
Médicaux : HTA, dyslipidémie, surpoids (IMC 28.5 kg/m²). Familiaux : cancer du côlon chez le frère à l'âge de 68 ans. Allergies : paracétamol.

Examens complémentaires
Coloscopie du 09/08/2025 : iléon, caecum et côlon d'aspect normal. Rectum : quelques polypes d'allure hyperplasiques.

Conclusion
Patient de 61 ans ayant consulté pour bilan endoscopique. Coloscopie bien préparée avec aspect normal. Pas d'anomalie retrouvée en dehors de polypes hyperplasiques du rectum. Prochain contrôle endoscopique dans 5 ans si l'état général le permet.

Fait à Versailles le 05/10/2025,
Signataire : Dr Emanuelle Chonavey.

Mais tous les CR comportent-ils une conclusion pouvant servir de référence ?

Les conclusions des CR sont-elles des résumés ?

Pour évaluer un résumé généré, on peut le comparer à un **résumé de référence**, c'est-à-dire un résumé validé qui sert de point de comparaison.

Dans le cadre du CU3, nous avons initialement fait l'hypothèse que les conclusions déjà présentes dans les CR pouvaient jouer ce rôle.

Compte rendu d'hospitalisation du service de Gastro-entérologie

Madame Gaela Berton, 71 ans, est hospitalisée en hôpital de jour de Gastro-entérologie le 09/08/2025.

Motif d'hospitalisation
Bilan endoscopique.

Antécédents médicaux, chirurgicaux, familiaux, allergies
Médicaux : HTA, dyslipidémie, surpoids (IMC 28.5 kg/m^2). Familiaux : cancer du côlon chez le frère à l'âge de 68 ans. Allergies : paracétamol.

Examens complémentaires
Coloscopie du 09/08/2025 : iléon, caecum et côlon d'aspect normal. Rectum : quelques polypes d'allure hyperplasiques.

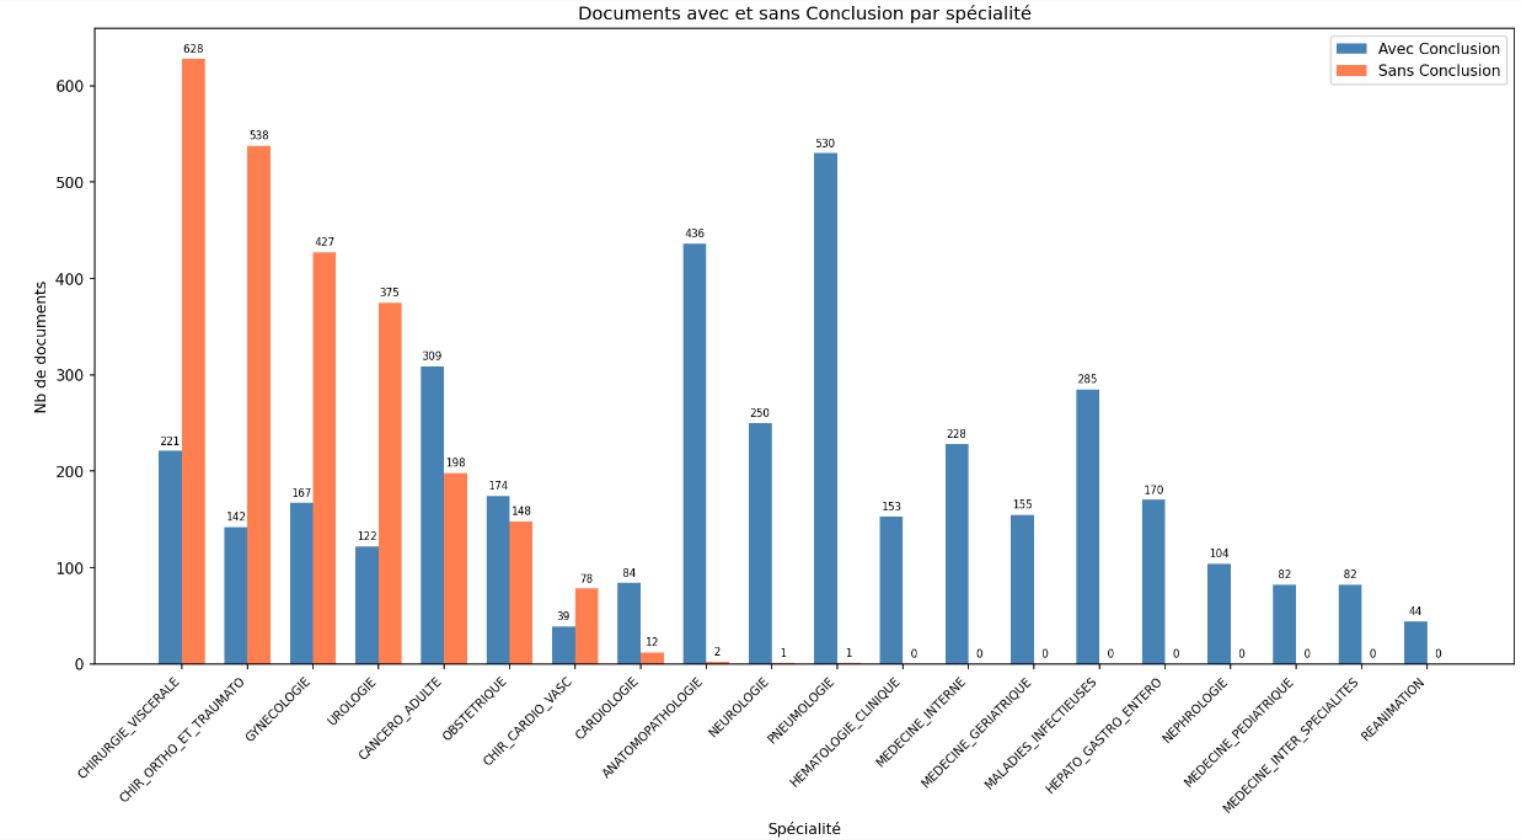
Conclusion
Patient de 61 ans ayant consulté pour bilan endoscopique. Coloscopie bien préparée avec aspect normal. Pas d'anomalie retrouvée en dehors de polypes hyperplasiques du rectum. Prochain contrôle endoscopique dans 5 ans si l'état général le permet.

Fait à Versailles le 05/10/2025,
Signataire : Dr Emanuelle Chonavey.

Mais tous les CR comportent-ils une conclusion pouvant servir de référence ?

Présence d'une conclusion explicite dans les CR

Sur les 6.189 CR du corpus PARHAF, combien comportent un paragraphe explicitement identifié comme une conclusion ?



~61% (3.777 / 6.189) des CR mentionnent explicitement une conclusion[2]

[2] Seuls les CR contenant un paragraphe commençant explicitement par « Conclusion » sont retenus : identifier automatiquement les conclusions formulées autrement nécessiterait une expertise médicale.

Une conclusion est-elle un résumé fiable ?

Même lorsqu'une conclusion est présente, elle ne constitue pas nécessairement un résumé fiable du CR : elle peut contenir des **informations absentes** du corps du CR ou des **erreurs factuelles**.

Compte rendu d'hospitalisation du service de Gastro-entérologie

Madame Gaela Berton, 71 ans, est hospitalisée en hôpital de jour de Gastro-entérologie le 09/08/2025.

Motif d'hospitalisation
Bilan endoscopique.

Antécédents médicaux, chirurgicaux, familiaux, allergies
Médicaux : HTA, dyslipidémie, surpoids (IMC 28.5 kg/m²). Familiaux : cancer du côlon chez le frère à l'âge de 68 ans. Allergies : paracétamol.

Histoire de la maladie
Patiente ayant consulté le Dr LEPELLE suite au diagnostic chez son frère d'un cancer du côlon métastatique en janvier 2025.

Examens complémentaires
Coloscopie du 09/08/2025 : iléon, caecum et côlon d'aspect normal. Rectum : quelques polypes d'allure hyperplasiques.

Conclusion

~~Patient~~ Patiente de ~~61~~ 71 ans ayant consulté pour bilan endoscopique. Coloscopie ~~bien préparée~~ avec aspect normal. Pas d'anomalie retrouvée en dehors de polypes hyperplasiques du rectum. ~~Prochain contrôle endoscopique dans 5 ans si l'état général le permet.~~

- **Erreurs factuelles :** genre et âge incohérents.
- **Information absente :** préparation de procédure et recommandation de suivi non présents dans le corps du CR.

Les conclusions existantes doivent donc être vérifiées et corrigées avant de servir de références.

Une conclusion est-elle un résumé fiable ?

Même lorsqu'une conclusion est présente, elle ne constitue pas nécessairement un résumé fiable du CR : elle peut contenir des **informations absentes** du corps du CR ou des **erreurs factuelles**.

Compte rendu d'hospitalisation du service de Gastro-entérologie

Madame Gaela Berton, 71 ans, est hospitalisée en hôpital de jour de Gastro-entérologie le 09/08/2025.

Motif d'hospitalisation
Bilan endoscopique.

Antécédents médicaux, chirurgicaux, familiaux, allergies
Médicaux : HTA, dyslipidémie, surpoids (IMC 28.5 kg/m²). Familiaux : cancer du côlon chez le frère à l'âge de 68 ans. Allergies : paracétamol.

Histoire de la maladie
Patiente ayant consulté le Dr LEPELLE suite au diagnostic chez son frère d'un cancer du côlon métastatique en janvier 2025.

Examens complémentaires
Coloscopie du 09/08/2025 : iléon, caecum et côlon d'aspect normal. Rectum : quelques polypes d'allure hyperplasiques.

Conclusion

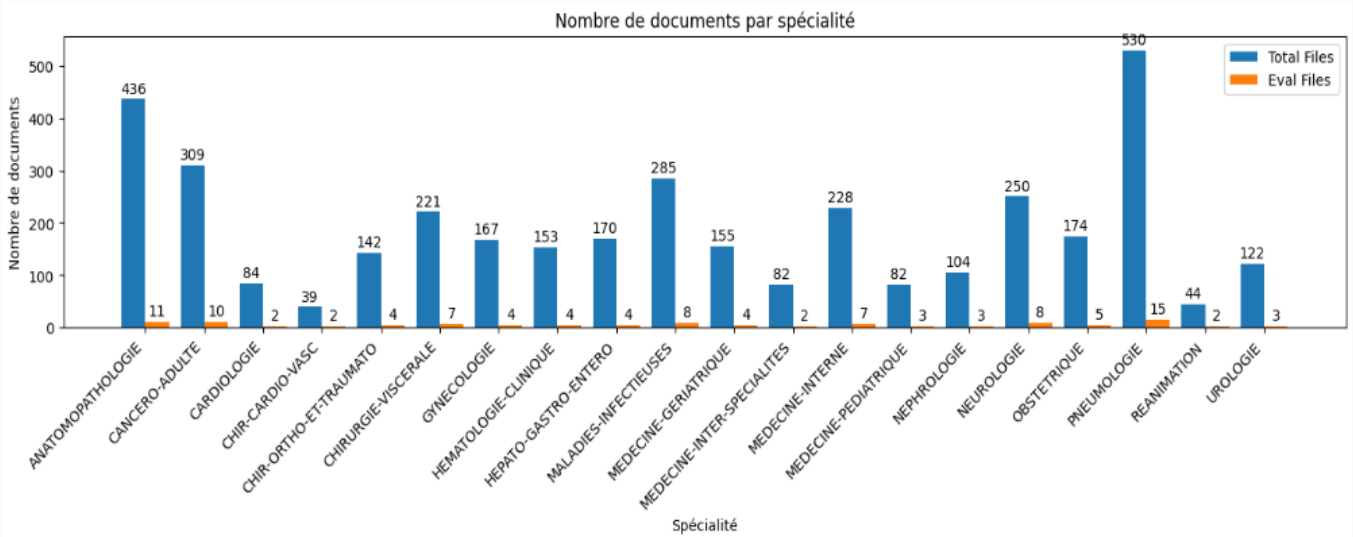
~~Patient~~ Patiente de ~~61~~ 71 ans ayant consulté pour bilan endoscopique. Coloscopie ~~bien préparée~~ avec aspect normal. Pas d'anomalie retrouvée en dehors de polypes hyperplasiques du rectum. ~~Prochain contrôle endoscopique dans 5 ans si l'état général le permet.~~

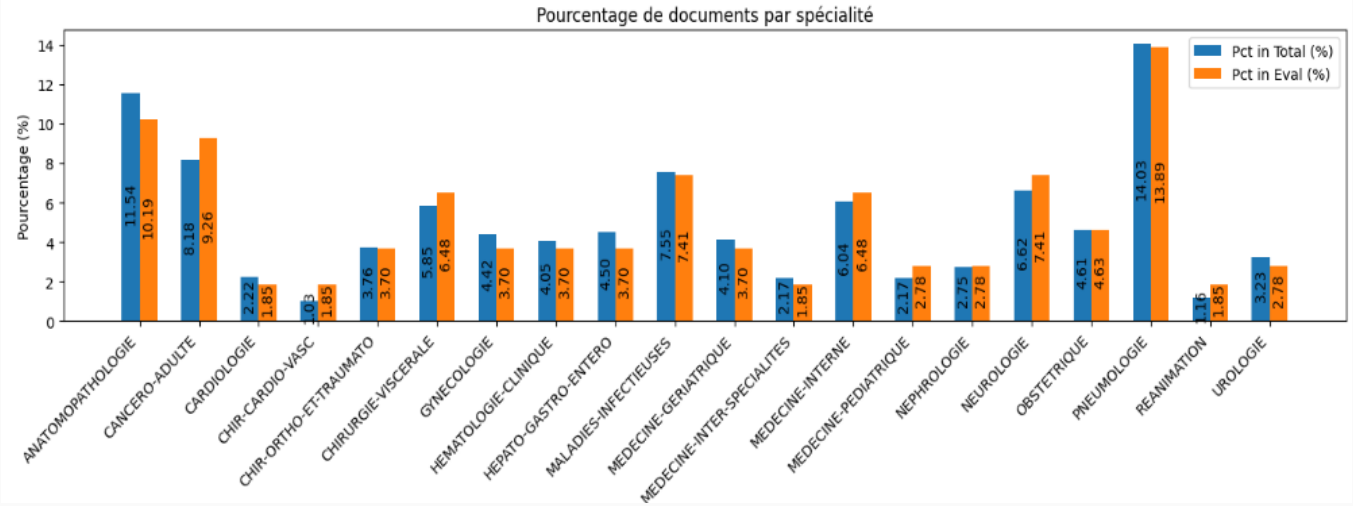
- Erreurs factuelles : genre et âge incohérents.
- Information absente : préparation de procédure et recommandation de suivi non présents dans le corps du CR.

Les conclusions existantes doivent donc être vérifiées et corrigées avant de servir de références.

Construire une référence fiable : constitution du sous-corpus

Dans un premier temps, nous avons sélectionné **108 CR avec conclusion explicite**, choisis pour la diversité des difficultés rencontrées lors de leur analyse.





Construire une référence fiable : l'annotation

Pour chacun des 108 CR, deux annotateurs (A et T) ont appliqué indépendamment les mêmes consignes afin de produire un résumé **fidèle et vérifiable à partir du document source :**

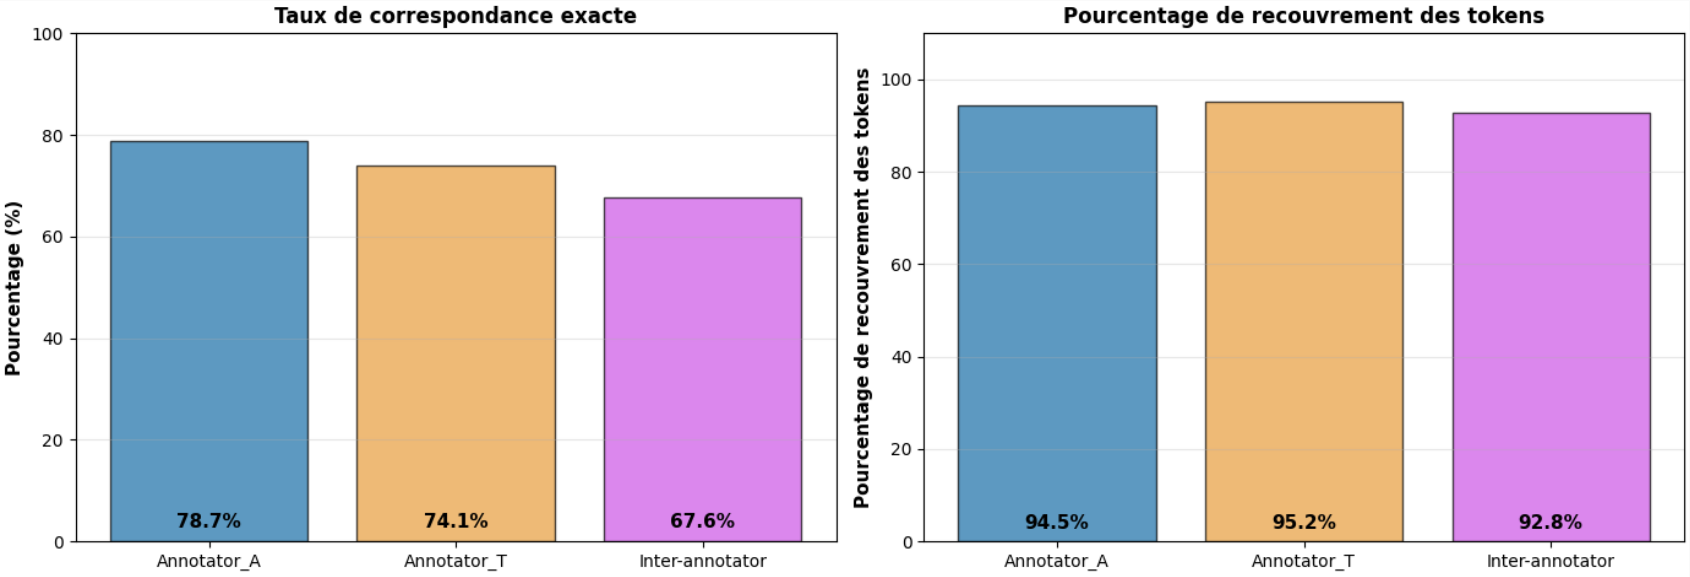
1. **Identifier** la conclusion du CR.
2. **Vérifier** chaque information à partir du corps du CR.
3. **Supprimer** les informations non étayées par le texte source.
4. **Corriger** les erreurs factuelles et typographiques.
5. **Préserver** au maximum la formulation et le contenu d'origine.

Objectif : obtenir des résumés vérifiés, utilisables comme références pour l'évaluation des résumés automatiques.

Accord inter-annotateurs : dans quelle mesure ?

Les deux annotateurs ont-ils abouti aux mêmes résumés après vérification et correction ?

- **Correspondance exacte :** annotations textuellement identiques.
- **Recouvrement des tokens :** recouvrement lexical entre les annotations.



En bleu : comparaison entre les résumés d'Annotator_A et les conclusions originales, en orange : comparaison entre les résumés d'Annotator_T et les conclusions originales, en magenta : comparaison entre les résumés de deux annotateurs.

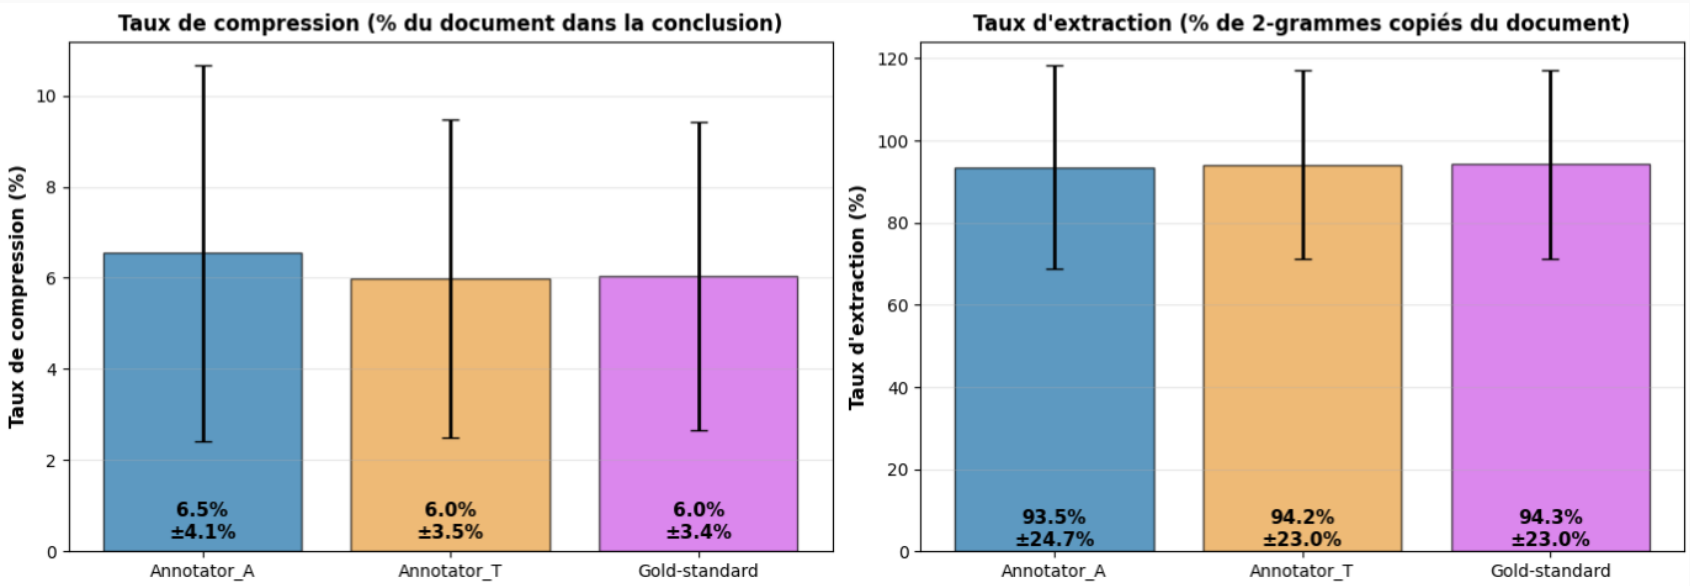
À retenir : un fort recouvrement lexical ($\sim$ **93%**), mais des annotations textuellement identiques dans seulement $\sim$ **68% des cas**.

Gold standard : compression et extraction

Les désaccords ont été résolus par consensus afin d'établir les résumés de référence.

Quelles sont les caractéristiques des résumés en termes de longueur et de fidélité au texte source ?

- **Taux de compression :** ratio entre la longueur du CR et le résumé.
- **Taux d'extraction :** % de mots du CR copiés verbatim dans le résumé.



À retenir : les résumes sont très concis (**compression** $\sim$ **6%**) et reprennent largement les formulations du CR source (**extraction** $\sim$ **94%**).

Des conclusions aux résumés de référence

Le travail d'annotation a permis de transformer les conclusions existantes en **résumés vérifiés à partir du document source**, utilisables comme références pour le CU3.

Deux corpus ont ainsi été constitués, pour le développement et l'évaluation des systèmes.

(1) Corpus de développement (108 CR)

Résumés vérifiés et corrigés manuellement, mis à disposition sur HuggingFace. [3]



(2) Corpus de test (337 CR)

Résumés annotés selon la même démarche, conservés privés afin de limiter les risques de fuite des données d'évaluation.

[3] *https://huggingface.co/datasets/HealthDataHub/PARHAF-conclusion-annotated*

Des conclusions aux résumés de référence

Le travail d'annotation a permis de transformer les conclusions existantes en **résumés vérifiés à partir du document source**, utilisables comme références pour le CU3.

Deux corpus ont ainsi été constitués, pour le développement et l'évaluation des systèmes.

(1) Corpus de développement (108 CR)

Résumés vérifiés et corrigés manuellement, mis à disposition sur HuggingFace. [3]



(2) Corpus de test (337 CR)

Résumés annotés selon la même démarche, conservés privés afin de limiter les risques de fuite des données d'évaluation.

[3] *https://huggingface.co/datasets/HealthDataHub/PARHAF-conclusion-annotated*

Annotation des résumés : principaux enseignements

Un travail d'annotation nécessaire

- Les conclusions initiales peuvent contenir des erreurs ou des informations non étayées.

Un accord inter-annotateurs élevé, mais non parfait

- Les divergences (extraction, corrections, équivalences sémantiques) nécessitent une résolution par consensus.

Des résumés courts et hétérogènes

- Forte compression, mais longueur et degré de reformulation variables selon les spécialités.
- Les informations retenues varient d'un CR à l'autre.

Disposer de résumés de référence fiables est une première étape ; reste à déterminer comment évaluer les résumés générés.

Annotation des résumés : principaux enseignements

Un travail d'annotation nécessaire

- Les conclusions initiales peuvent contenir des erreurs ou des informations non étayées.

Un accord inter-annotateurs élevé, mais non parfait

- Les divergences (extraction, corrections, équivalences sémantiques) nécessitent une résolution par consensus.

Des résumés courts et hétérogènes

- Forte compression, mais longueur et degré de reformulation variables selon les spécialités.
- Les informations retenues varient d'un CR à l'autre.

Disposer de résumés de référence fiables est une première étape ; reste à déterminer comment évaluer les résumés générés.

Annotation des résumés : principaux enseignements

Un travail d'annotation nécessaire

- Les conclusions initiales peuvent contenir des erreurs ou des informations non étayées.

Un accord inter-annotateurs élevé, mais non parfait

- Les divergences (extraction, corrections, équivalences sémantiques) nécessitent une résolution par consensus.

Des résumés courts et hétérogènes

- Forte compression, mais longueur et degré de reformulation variables selon les spécialités.
- Les informations retenues varient d'un CR à l'autre.

Disposer de résumés de référence fiables est une première étape ; reste à déterminer comment évaluer les résumés générés.

Annotation des résumés : principaux enseignements

Un travail d'annotation nécessaire

- Les conclusions initiales peuvent contenir des erreurs ou des informations non étayées.

Un accord inter-annotateurs élevé, mais non parfait

- Les divergences (extraction, corrections, équivalences sémantiques) nécessitent une résolution par consensus.

Des résumés courts et hétérogènes

- Forte compression, mais longueur et degré de reformulation variables selon les spécialités.
- Les informations retenues varient d'un CR à l'autre.

Disposer de résumés de référence fiables est une première étape ; reste à déterminer comment évaluer les résumés générés.

Comment évalue-t-on la pertinence d’un résumé ?

Pourquoi une seule référence ne suffit-elle pas pour évaluer ?

Nous disposons de résumés annotées, mais **une référence ne représente pas toutes les possibilités de résumé**.

- **Une référence imparfaite**
  - Accord exact entre annotateurs : 68,5 %.
  - Le consensus reste un choix parmi plusieurs formulations possibles.
- **Plusieurs résumés valides**
  - Un même CR peut être résumé de différentes façons.
  - Des résumés pertinents peuvent retenir des informations différentes.

Un résumé différent de la référence n'est pas nécessairement un mauvais résumé.

Mais comment évalue-t-on sa qualité ?

Pourquoi une seule référence ne suffit-elle pas pour évaluer ?

Nous disposons de résumés annotées, mais **une référence ne représente pas toutes les possibilités de résumé**.

- **Une référence imparfaite**
  - Accord exact entre annotateurs : 68,5 %.
  - Le consensus reste un choix parmi plusieurs formulations possibles.
- **Plusieurs résumés valides**
  - Un même CR peut être résumé de différentes façons.
  - Des résumés pertinents peuvent retenir des informations différentes.

Un résumé différent de la référence n'est pas nécessairement un mauvais résumé.

Mais comment évalue-t-on sa qualité ?

Deux approches complémentaires d'évaluation

La **similarité à une référence** et la **fidélité à la source** mesurent des **propriétés différentes**.

1. Comparer le résumé à évaluer au résumé de référence

- **Question :** le résumé généré ressemble-t-il au résumé de référence ?
- **Exemple d'évaluation :** comparer les tokens ou mots communs entre le résumé généré et la référence.
- **Limite :** une formulation différente peut être pénalisée même si elle est correcte.

2. Comparer le résumé à évaluer au CR source

- **Question :** le résumé est-il fidèle au document source et couvre-t-il les informations importantes ?
- **Exemple d'évaluation :** vérifier qu'un fait mentionné dans le résumé est bien étayé par le CR.
- **Limite :** la fidélité ne garantit pas que le résumé retient les informations les plus pertinentes.

Deux approches complémentaires d'évaluation

La **similarité à une référence** et la **fidélité à la source** mesurent des **propriétés différentes**.

1. Comparer le résumé à évaluer au résumé de référence

- **Question :** le résumé généré ressemble-t-il au résumé de référence ?
- **Exemple d'évaluation :** comparer les tokens ou mots communs entre le résumé généré et la référence.
- **Limite :** une formulation différente peut être pénalisée même si elle est correcte.

2. Comparer le résumé à évaluer au CR source

- **Question :** le résumé est-il fidèle au document source et couvre-t-il les informations importantes ?
- **Exemple d'évaluation :** vérifier qu'un fait mentionné dans le résumé est bien étayé par le CR.
- **Limite :** la fidélité ne garantit pas que le résumé retient les informations les plus pertinentes.

Deux évaluations, deux perspectives

Compte rendu d'hospitalisation du service de Gastro-entérologie

Madame Gaela Berton, 71 ans, est hospitalisée en hôpital de jour de Gastro-entérologie le 09/08/2025.

Motif d'hospitalisation Bilan endoscopique.

Antécédents Médicaux : HTA, dyslipidémie, surpoids (IMC 28.5 kg/m²). [...] Allergies : paracétamol. [...]

Examens complémentaires Coloscopie : iléon, caecum et côlon d'aspect normal. Rectum : quelques polypes d'allure hyperplasiques.

Résumé de référence (hybride) :

> *Patiente de 71 ans ayant consulté pour bilan endoscopique. Coloscopie bien préparée avec aspect normal. Pas d'anomalie retrouvée en dehors de polypes hyperplasiques du rectum.*

Résumé A (extractif)

« *Bilan endoscopique. Allergies : paracétamol. Iléon, caecum et côlon d'aspect normal. Rectum : quelques polypes d'allure hyperplasiques.* »

vs référence : Recouvrement lexical partiel (sélection et formulation différentes) ; l'ajout de l'allergie (absente de la référence) peut pénaliser le score.

vs source : Informations fidèles ; l'ajout de l'allergie n'est pas pénalisé même si sa pertinence dépend de l'objectif du résumé.

Deux évaluations, deux perspectives

Compte rendu d'hospitalisation du service de Gastro-entérologie

Madame Gaela Berton, 71 ans, est hospitalisée en hôpital de jour de Gastro-entérologie le 09/08/2025.

Motif d'hospitalisation Bilan endoscopique.

Antécédents Médicaux : HTA, dyslipidémie, surpoids (IMC 28.5 kg/m²). [...] Allergies : paracétamol. [...]

Examens complémentaires Coloscopie : iléon, caecum et côlon d'aspect normal. Rectum : quelques polypes d'allure hyperplasiques.

Résumé de référence (hybride) :

> *Patiente de 71 ans ayant consulté pour bilan endoscopique. Coloscopie bien préparée avec aspect normal. Pas d'anomalie retrouvée en dehors de polypes hyperplasiques du rectum.*

Résumé A (extractif)

« *Bilan endoscopique. Allergies : paracétamol. Iléon, caecum et côlon d'aspect normal. Rectum : quelques polypes d'allure hyperplasiques.* »

vs référence : Recouvrement lexical partiel (sélection et formulation différentes) ; l'ajout de l'allergie (absente de la référence) peut pénaliser le score.

vs source : Informations fidèles ; l'ajout de l'allergie n'est pas pénalisé même si sa pertinence dépend de l'objectif du résumé.

Résumé B (hybride)

« *Madame Berton, 71 ans, est hospitalisée pour bilan endoscopique. La coloscopie retrouve un tube digestif d'aspect normal, hormis quelques polypes rectaux d'allure hyperplasique. L'examen se déroule sans complication.* »

vs référence : Contenu proche, mais reformulation susceptible de réduire le score lexical.

vs source : Informations globalement fidèles avec quelques reformulations, l'ajout de « sans complication » (n'est pas étayé par la source) peut pénaliser le score.

La similarité à la référence ne suffit pas à garantir la fidélité au document source.
La similarité au document source ne suffit pas à garantir la pertinence des informations incluses.

Deux évaluations, deux perspectives

Compte rendu d'hospitalisation du service de Gastro-entérologie

Madame Gaela Berton, 71 ans, est hospitalisée en hôpital de jour de Gastro-entérologie le 09/08/2025.

Motif d'hospitalisation Bilan endoscopique.

Antécédents Médicaux : HTA, dyslipidémie, surpoids (IMC 28.5 kg/m²). [...] Allergies : paracétamol. [...]

Examens complémentaires Coloscopie : iléon, caecum et côlon d'aspect normal. Rectum : quelques polypes d'allure hyperplasiques.

Résumé de référence (hybride) :

> *Patiente de 71 ans ayant consulté pour bilan endoscopique. Coloscopie bien préparée avec aspect normal. Pas d'anomalie retrouvée en dehors de polypes hyperplasiques du rectum.*

Résumé A (extractif)

« *Bilan endoscopique. Allergies : paracétamol. Iléon, caecum et côlon d'aspect normal. Rectum : quelques polypes d'allure hyperplasiques.* »

vs référence : Recouvrement lexical partiel (sélection et formulation différentes) ; l'ajout de l'allergie (absente de la référence) peut pénaliser le score.

vs source : Informations fidèles ; l'ajout de l'allergie n'est pas pénalisé même si sa pertinence dépend de l'objectif du résumé.

Résumé B (hybride)

« *Madame Berton, 71 ans, est hospitalisée pour bilan endoscopique. La coloscopie retrouve un tube digestif d'aspect normal, hormis quelques polypes rectaux d'allure hyperplasique. L'examen se déroule sans complication.* »

vs référence : Contenu proche, mais reformulation susceptible de réduire le score lexical.

vs source : Informations globalement fidèles avec quelques reformulations, l'ajout de « sans complication » (n'est pas étayé par la source) peut pénaliser le score.

La similarité à la référence ne suffit pas à garantir la fidélité au document source.
La similarité au document source ne suffit pas à garantir la pertinence des informations incluses.

Évaluer un résumé clinique : un défi à plusieurs niveaux

- **Pas de référence parfaite ni unique**
  - Plusieurs résumés peuvent être valides pour un même CR.
  - Construire des références fiables nécessite un travail d'annotation rigoureux.

- **Pas de métrique parfaite non plus**
  - La comparaison à une référence mesure la similarité, mais pas toute la qualité.
  - La comparaison à la source permet d'évaluer la fidélité, mais ne suffit pas à juger la pertinence ni la couverture de l'information.

Une évaluation plus complète nécessite de combiner plusieurs approches : comparer le résumé à une référence et vérifier sa fidélité au CR source.

Au final, la qualité d'un résumé clinique ne se résume ni à une référence unique, ni à un score unique.

Évaluer un résumé clinique : un défi à plusieurs niveaux

- **Pas de référence parfaite ni unique**
  - Plusieurs résumés peuvent être valides pour un même CR.
  - Construire des références fiables nécessite un travail d'annotation rigoureux.

- **Pas de métrique parfaite non plus**
  - La comparaison à une référence mesure la similarité, mais pas toute la qualité.
  - La comparaison à la source permet d'évaluer la fidélité, mais ne suffit pas à juger la pertinence ni la couverture de l'information.

Une évaluation plus complète nécessite de combiner plusieurs approches : comparer le résumé à une référence et vérifier sa fidélité au CR source.

Au final, la qualité d'un résumé clinique ne se résume ni à une référence unique, ni à un score unique.



EcAuTAL

École d'Automne en TAL

Exploration d'un corpus clinique : un cas d'étude du projet PARTAGES

Laura Zanella

Postdoctorante, LISN, équipe SEME

22 octobre 2026

LISN
LABORATOIRE INTERDISCIPLINAIRE DES SCIENCES DU NUMÉRIQUE

cnrs

université PARIS-SACLAY

PARTAGES
DévelopPement Avancé de communs numéRiques pour l'inTelligence Artificielle Générative En Santé

Mise en pratique : exploration et évaluation des résumés

Dans un notebook, nous allons mettre en pratique les notions abordées à travers trois étapes :

1. **Explorer le corpus et les défis de l'annotation**
   - Statistiques descriptives et exemples d'erreurs factuelles.
2. **Analyser l'accord entre annotateurs**
   - Calcul des métriques et analyse de cas de désaccord.
3. **Évaluer des résumés générés**
   - Comparaison aux références et au CR source.
   - Analyse de cas où les deux approches se complètent.